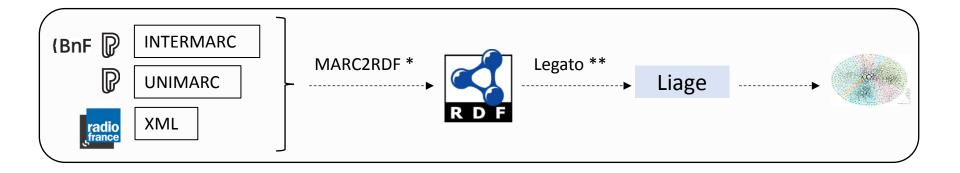








Projet DOREMUS









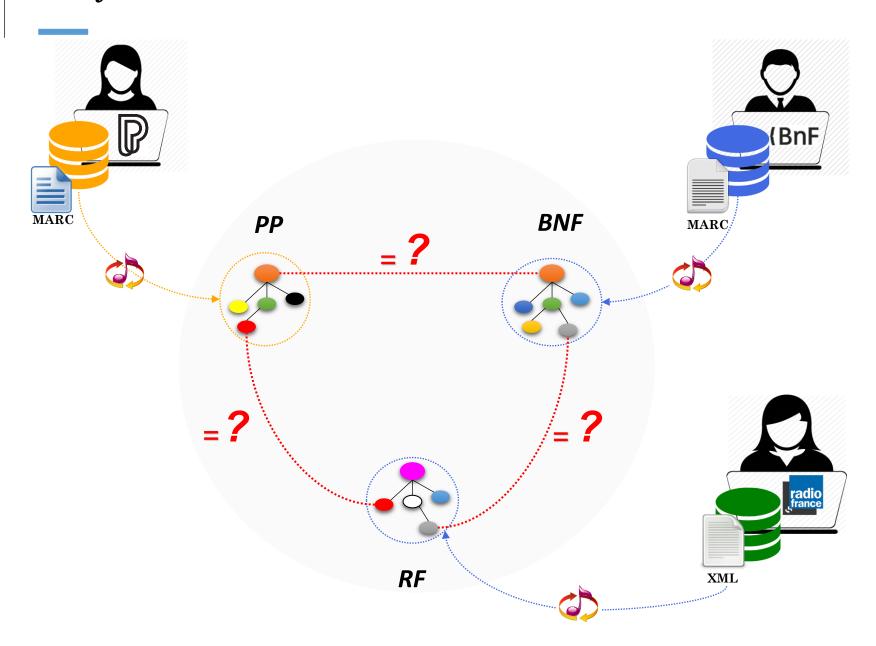


MEANING ENGINES

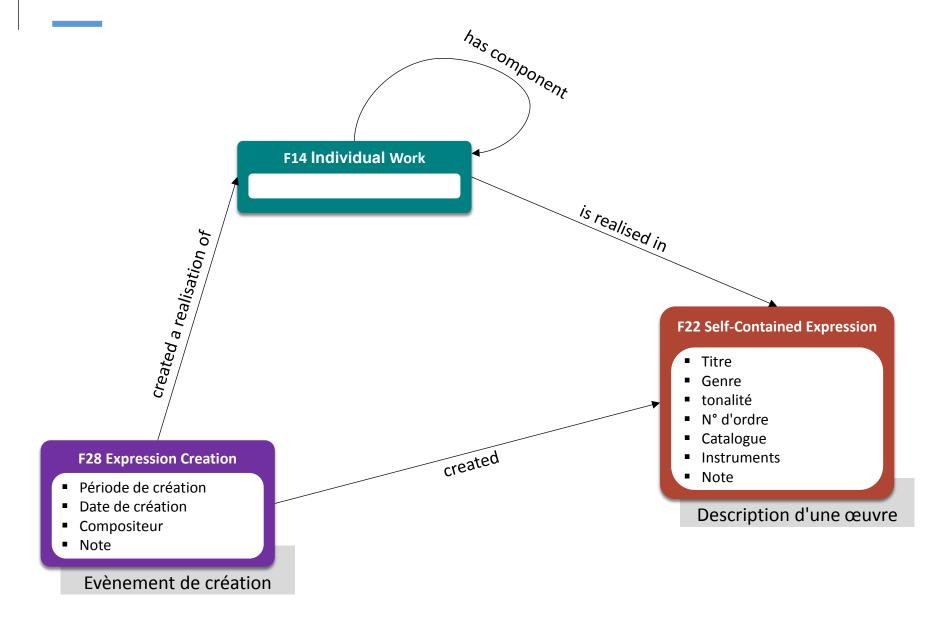
(*): https://github.com/DOREMUS-ANR/marc2rdf

(**): https://github.com/DOREMUS-ANR/legato

Projet DOREMUS



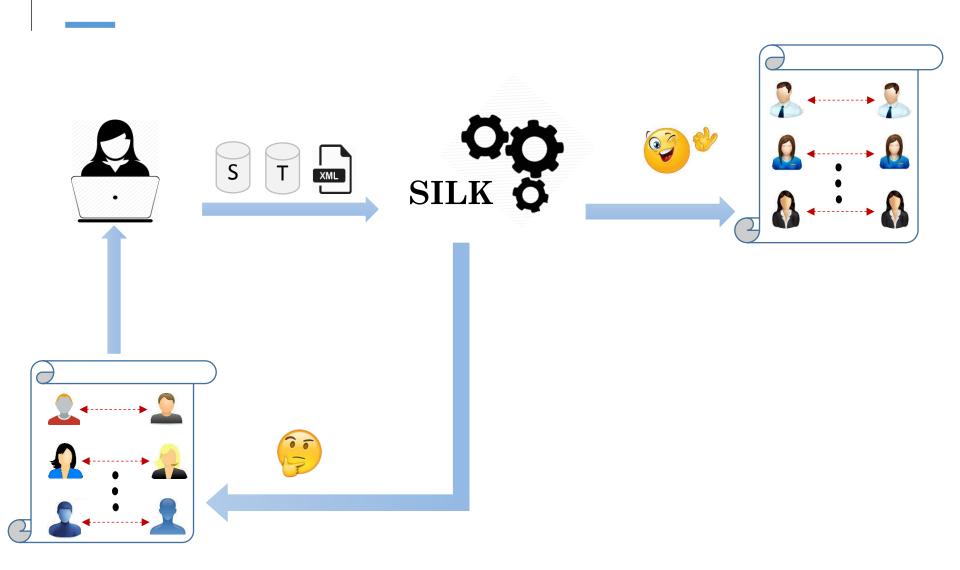
Modèle de DOREMUS



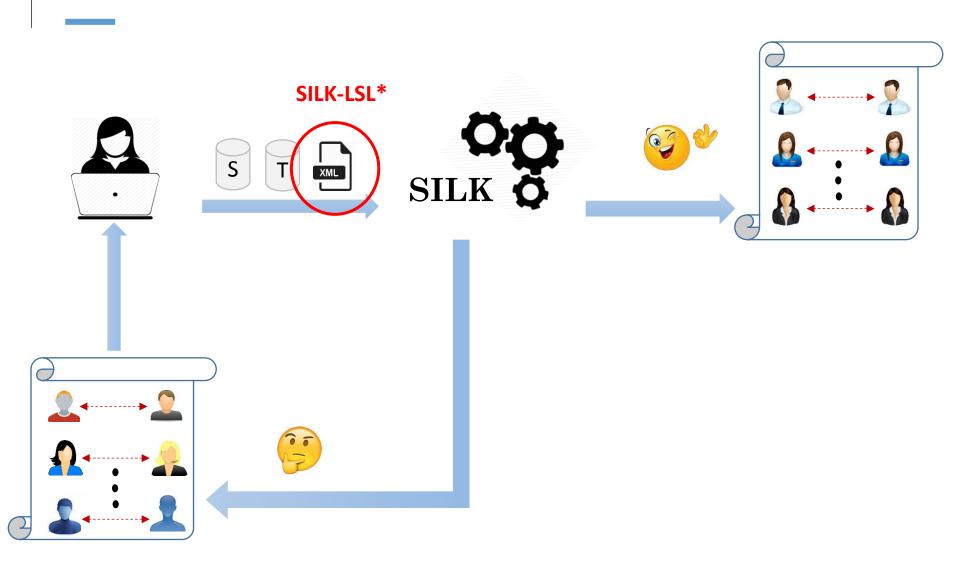
```
<a href="http://data.doremus.org/expression/d72301f0-0aba-3ba6-93e5-c4efbee9c6ea">http://data.doremus.org/expression/d72301f0-0aba-3ba6-93e5-c4efbee9c6ea</a>
                         efrbroo:F22 Self-Contained Expression;
                 mus:U70 has title "Clair de lune"@fr, "Sonate Clair de lune"@fr, "Quasi una fantasia"@it,
                 "Mondschein-Sonate" @de, "Sonates @fr, "Quasi una fantasia" @it, "Sonata quasi una fantasia" @it,
                 "Moonlight sonata"@en;
                 mus:U10 has order number "14"^^xsd:int;
                 mus:U11 has key <a href="http://data.doremus.org/vocabulary/key/cxm">http://data.doremus.org/vocabulary/key/cxm</a>;
                 mus:U12 has genre <a href="http://data.doremus.org/vocabulary/iaml/genre/sn">http://data.doremus.org/vocabulary/iaml/genre/sn</a>;
                 mus:U13 has casting <a href="http://data.doremus.org/expression/d72301f0-0aba-3ba6-93e5-c4efbee9c6ea/casting/1">http://data.doremus.org/expression/d72301f0-0aba-3ba6-93e5-c4efbee9c6ea/casting/1>;
                 mus:U17 has opus statement <a href="http://data.doremus.org/expression/d72301f0-0aba-3ba6-93e5-c4efbee9c6ea/opus/27-2">http://data.doremus.org/expression/d72301f0-0aba-3ba6-93e5-c4efbee9c6ea/opus/27-2>;
                 dcterms:identifier "13908188";
 <a href="http://data.doremus.org/event/3f9d2fae-da75-3c66-902d-fa3a0755d892">http://data.doremus.org/event/3f9d2fae-da75-3c66-902d-fa3a0755d892</a>
                           efrbroo:F28 Expression Creation;
                 efrbroo:R17 created <a href="http://data.doremus.org/expression/d72301f0-0aba-3ba6-93e5-c4efbee9c6ea">efrbroo:R17 created <a href="http://data.doremus.org/expression/expression/d72301f0-0aba-3ba6-93e5-c4efbee9c6ea">efrbroo:R17 created <a href="http://data.doremus.org/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expression/expr
                 efrbroo:R19 created a realisation of <a href="http://data.doremus.org/work/30256b51-d277-3688-ad62-560ae982ff2f">http://data.doremus.org/work/30256b51-d277-3688-ad62-560ae982ff2f</a>;
                 ecrm:P9 consists of <a href="http://data.doremus.org/event/3f9d2fae-da75-3c66-902d-fa3a0755d892/activity/1">http://data.doremus.org/event/3f9d2fae-da75-3c66-902d-fa3a0755d892/activity/1>;
                 ecrm:P4 has time-span <a href="http://data.doremus.org/event/3f9d2fae-da75-3c66-902d-fa3a0755d892/time">http://data.doremus.org/event/3f9d2fae-da75-3c66-902d-fa3a0755d892/time</a>;
-<a href="http://data.doremus.org/work/30256b51-d277-3688-ad62-560ae982ff2f">http://data.doremus.org/work/30256b51-d277-3688-ad62-560ae982ff2f</a>
                                                                                                                                                                                                                                                          created a realisation of
                           efrbroo:F14 Individual Work;
                efrbroo:R9 is realised in <a href="http://data.doremus.org/expression/d72301f0-0aba-3ba6-93e5-c4efbee9c6ea">http://data.doremus.org/expression/d72301f0-0aba-3ba6-93e5-c4efbee9c6ea</a>;
```

:s realiser

SILK: Framework de Découverte de Liens



SILK: Framework de Découverte de Liens



SILK-LSL

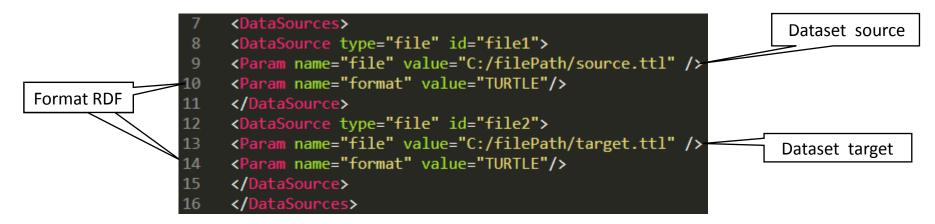
- 1. Les préfixes
- 2. Les sources de données
 - a. Jeu de données "source"
 - b. Jeu de données "target"
- 3. Les types
 - a. Lien à générer
 - b. Ressources à comparer
- 4. Les règles de liage
 - a. Mesures de similarité
 - b. Propriétés à comparer
- 5. Les Paramètres de sortie
 - a. Liens sûrs
 - b. Liens à vérifier

SILK-LSL

```
<?xml version="1.0" encoding="UTF-8"?>
                                  <Prefix id="rdf" namespace="http://www.w3.org/1999/02/22-rdf-syntax-ns#"/</pre>
                                                                                                                  Préfixes
                                 <Prefix id="property" namespace="http://example.property.org/ontology#" /</pre>
                                  </Prefixes>
                                  <DataSources>
                                  <DataSource type="file" id="file1">
                                                                                                    Dataset source
                                  <Param name="file" value="C:/filePath/source.ttl" />
                                  <Param name="format" value="TURTLE"/>
                                  </DataSource>
                                  <DataSource type="file" id="file2">
                                                                                                    Dataset target
                                 <Param name="file" value="C:/filePath/target.ttl" />
                                 <Param name="format" value="TURTLE"/>
                                 </DataSource>
</DataSources>
      Type de lien
                                  <Interlink id="resources">
                                  <LinkType>owl:sameAs</LinkType>
                                  <SourceDataset dataSource="file1" var="a">
                                  <RestrictTo> ?a a property:resourceType . </RestrictTo>
                                  </SourceDataset>
                                                                                                     Types de ressources à comparer
                                  <TargetDataset dataSource="file2" var="b">
                                 <RestrictTo> ?b a property:resourceType . </RestrictTo>
                                 </TargetDataset>
                                 <Aggregate type="average">
                                 <Compare metric="levenshtein" threshold="1" required="true">
                                 <Input path="?a/property:p1" />
                                 <Input path="?b/property:p2" />
                                                                           Propriétés à comparer
                                  </Compare>
                                  </Aggregate>
  Seuil de similarité
                                 <Filter limit="1" />
                                 </LinkageRule>
                                  <Output type="file" minConfidence="0.8">
                                  <Param name="file" value="results.rdf" />
                                                                                 Fichier de sortie "liens sûrs"
Format d'alignement
                                  <Param name="format" value="alignment" />
                                  </Output>
                                 <Output type="file" maxConfidence="1.0">
                                                                                  Fichier de sortie "liens à vérifier"
                                  <Param name="file" value="verify.rdf" />
                                 <Param name="format" value="alignment" />
                                  </0utput>
                                  </Outputs>
                                  </Interlink>
                                  </Interlinks>
                                  </Silk>
```

SILK-LSL: Les sources de données

1. Chemins vers des dumps en RDF



2. Lien vers le SPARQL endpoint

SILK-LSL: Les sources de données

1. Chemins vers des dumps en RDF

Format ("RDF/XML", "N-TRIPLE", "TURTLE", "TTL", "N3").

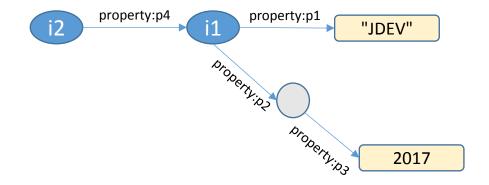
SILK-LSL: Les sources de données

1. Chemins vers des dumps en RDF



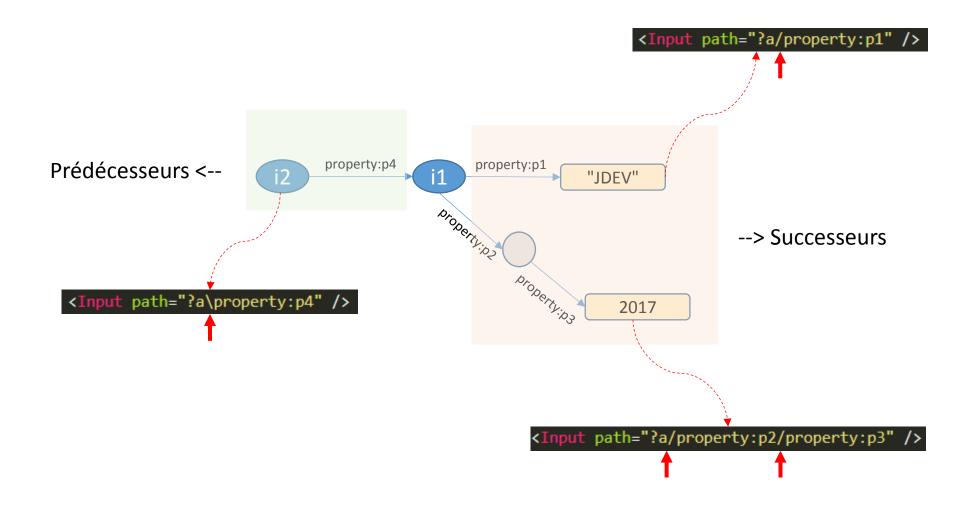
SILK-LSL: Régles de Liage

1. Chemin vers les propriétés à comparer



SILK-LSL: Régles de Liage

1. Chemin vers les propriétés à comparer



SILK-LSL : Régles de Liage

1. Chemin vers les propriétés à comparer

2. Fonctions de transformation: tokenisation, forme minuscule, etc.

- 3. Comparaison: mesures de similarité, seuil, etc.
 - ☐ Possibilité de comparer plusieurs paires de propriétés --> plusieurs blocs de <compare> ... </compare>

SILK-LSL: Aggrégations

```
<Aggregate type="average">
     <Compare metric="levenshtein" threshold="1">
         <TransformInput function="tokenize">
             <Input path="?a/property:p1" />
40
         </TransformInput>
41
         <TransformInput function="tokenize">
42
43
             <Input path="?b/property:p2" />
44
         </TransformInput>
45
     </Compare>
     </Aggregate>
```

Туре	Description
average	La moyenne des valeurs de confiance
min	La valeur de confiance la moins élevée
max	La valeur de confiance la plus élevée

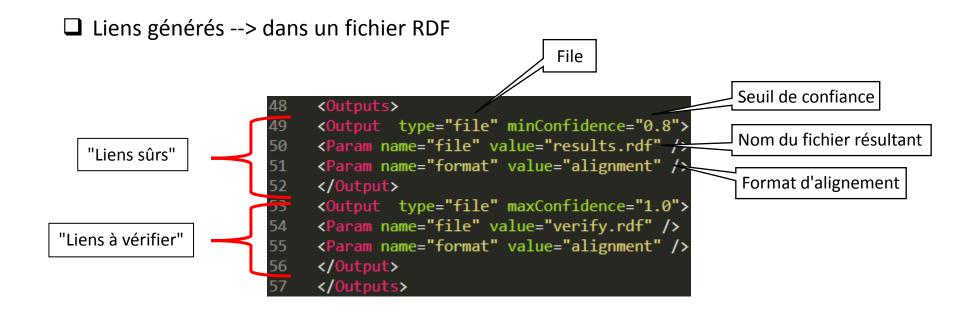
☐ <u>Valeur de confiance</u>: SILK convertit une distance calculée (par exemple la valeur 2 de Levenshtein) en une valeur de confiance entre -1 et +1.

Plus la valeur augmente et plus la similarité entre les instances augmente

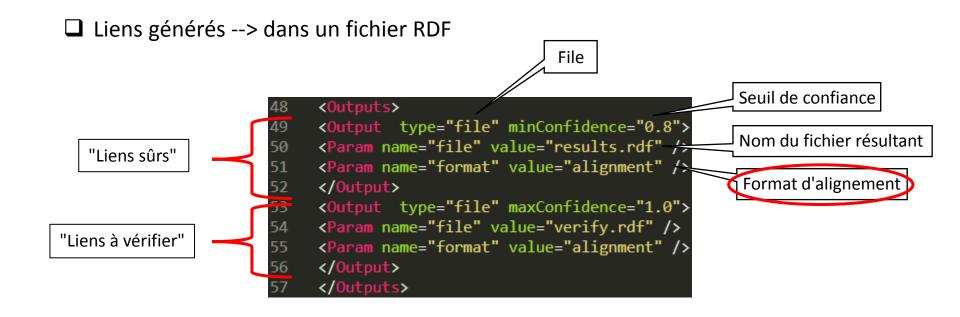
SILK-LSL: Mesures de similarité

Mesure de similarité	Description
levenshteinDistance	Nombre minimum d'éditions (insertion/suppression/substitution) pour transformer un string à un autre
levenshtein	Distance levenshtein normalisée dans un intervalle de [0,1]
jaro	Similarité entre chaines de caratcères basée sur la mesure de Jaro
jaroWinkler	Similarité entre chaines de caratcères basée sur la mesure de Jaro-Winkler
equality	Retourne 0 si les chaînes de caratères sont égales, sinon 1
date	similarité entre 2 dates au format AAAA-MM-JJ
jaccard	Similarité entre chaines de caratcères basée sur la distance de Jaccard

SILK-LSL: Les fichiers de sortie



SILK-LSL: Les fichiers de sortie



Format d'alignement ("N-TRIPLE", "alignement").

Possibilité de définir de 1 à n (n>1) blocs de <output> ... </output>

SILK-LSL: Définir plusieurs fichiers de sortie

```
59
     <Outputs>
         <Output type="file" minConfidence="lower threshold" maxConfidence="upper threshold">
61
             <Param name="file" value="file name" />
62
             <Param name="format" value="alignment format" />
         </Output>
64
65
         <Output type="file" minConfidence="lower threshold" maxConfidence="upper threshold">
             <Param name="file" value="file name" />
67
             <Param name="format" value="alignment format" />
         </Output>
69
     </Outputs>
```

SILK: Mode Ligne de Commande

- ☐ Entrées:
 - 2 jeux de données:
 - 1 fichier de configuration (LSL): Un exemple détaillé --> https://app.assembla.com/wiki/show/silk/Link_Specification_Language
 - "SILK.jar":

https://github.com/silk-framework/silk/releases (la version de SILK utilisée dans ce tutoriel est 2.6.1)

☐ Commande:

java -DconfigFile= configFile.xml -jar silk.jar

SILK: Exo-1

☐ Entrées:

- 2 jeux de données "source" et "target": https://github.com/manoach/JDEV2017-SILK-/tree/master/DFP
- 1 fichier de configuration (LSL): Un exemple détaillé --> https://app.assembla.com/wiki/show/silk/Link_Specification_Language
- "SILK.jar": https://github.com/manoach/JDEV2017-SILK-/tree/master/DFP

☐ A faire:

- Lier les instances de type http://erlangen-crm.org/efrbroo/F22_Self-Contained_Expression en comparant leur(s):
 - + Titres http://erlangen-crm.org/current/P102_has_title (en tokenisant les valeurs)
 - + Numéro d'ordre http://data.doremus.org/ontology#U10_has_order_number
 - + La note de leur opus http://data.doremus.org/ontology#U17_has_opus_statement
- Mesure: Levenshtein
- Seuil Levenshtein = 2
- Seuil d'aggrégation = 0.8
- Mapping attendu --> 1:1 (une instance "source" possède au plus une "instance" target).

SILK: Exo-2

Entrées:

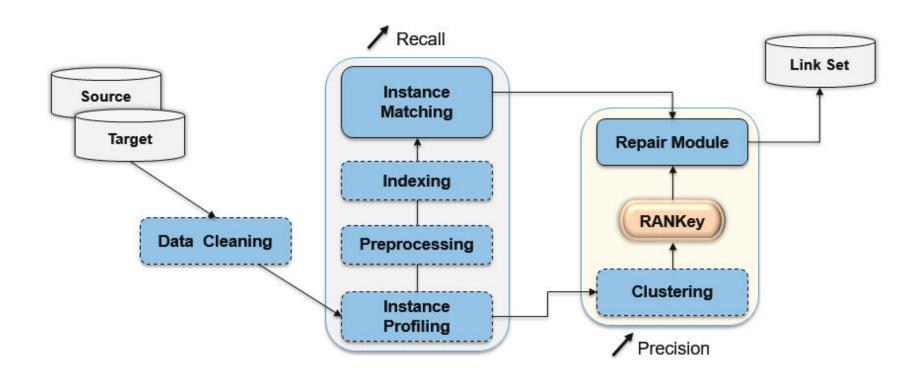
- 2 jeux de données "source" et "target": https://github.com/manoach/JDEV2017-SILK-/tree/master/DHT
- 1 fichier de configuration (LSL):

 Un exemple détaillé --> https://app.assembla.com/wiki/show/silk/Link_Specification_Language
- "SILK.jar": https://github.com/manoach/JDEV2017-SILK-/tree/master/DHT

☐ A faire:

- Lier les instances de type http://erlangen-crm.org/efrbroo/F22_Self-Contained_Expression en comparant leur(s):
 - + Notes http://erlangen-crm.org/current/P3_has_note (avec les paramètres de votre choix)

Legato: Workflow



Legato: Instance Profiling

